

HAR

15,63M
μετρήσεις

51 άτομα • 18
δραστηριότητες

PySpark MLlib
Google Cloud

Κατανεμημένη Αναγνώριση Ανθρώπινης Δραστηριότητας

HAR: αναγνώριση δραστηριότητας από κινήσεις που καταγράφουν κινητό και smartwatch.

WISDM: δημόσιο dataset 51 ατόμων και 18 δραστηριοτήτων.
Σύγκριση Logistic Regression και Random Forest με PySpark στο Google Cloud.

Κώστας Φύκατας

Ακαδημαϊκό έτος 2025-2026

Γιατί αυτό το πρόβλημα;

- Wearables και τηλέφωνα παράγουν συνεχείς, πολυδιάστατες χρονοσειρές.
- Η HAR υποστηρίζει υγεία, άθληση, υποβοηθούμενη διαβίωση και ασφάλεια.
- Το ζητούμενο δεν είναι μόνο accuracy: χρειάζεται distributed pipeline και cloud εκτέλεση.

RQ1

Ποιο μοντέλο γενικεύει σε νέα άτομα;

RQ2

Συσκευή, fusion ή window;

RQ3

Ίδιος κώδικας local και cloud;

RQ4

Ποιότητα έναντι χρόνου/κόστους;

Στόχος

**End-to-end • leakage-safe •
reproducible • cloud-ready**

WISDM: δεδομένα από κινητό και smartwatch

03

15,63 M

μετρήσεις
αισθητήρων

51

συμμετέχοντες

18

δραστηριότητες

20 Hz

ρυθμός
δειγματοληψίας

CC BY 4.0

DOI
10.24432/C5HK59

Τι είναι; 15.630.426 μετρήσεις από ανθρώπους που εκτελούν γνωστές δραστηριότητες. 20 Hz = 20 μετρήσεις ανά δευτερόλεπτο.

4 ροές αισθητήρων

PHONE

accelerometer

PHONE

gyroscope

WATCH

accelerometer

WATCH

gyroscope

18 κλάσεις — από walking/jogging έως typing, eating, writing και folding clothes

Από τις μετρήσεις στα χαρακτηριστικά με Spark

04



Παράθυρο: ομάδα μετρήσεων από 5 ή 10 s

Χαρακτηριστικό: αριθμός που συνοψίζει την κίνηση

- mean, std, min, max για x / y / z
- magnitude mean/std και mean energy
- corr(x,y), corr(x,z), corr(y,z)
- ≥ 150 samples στο κύριο window 10 s

$$m = \sqrt{x^2 + y^2 + z^2}$$
$$\text{window_id} = \lfloor \text{timestamp} / T_v \rfloor$$

Fusion: 18 accel + 18 gyro = 36 αριθμοί ανά παράθυρο

Χωρισμός ανά άνθρωπο: αποφυγή διαρροής

05

Λάθος: random split παραθύρων

Το ίδιο άτομο εμφανίζεται σε train και test → διαρροή προσωπικών μοτίβων → υπεραισιόδοξη επίδοση.

Δική μας επιλογή

Σταθερό SHA-256 ανά subject → ακριβώς 35 / 8 / 8 άτομα. Το test περιέχει μόνο άγνωστους συμμετέχοντες.

35 άτομα

TRAIN • εκπαίδευση
μοντέλου

8 άτομα

VALIDATION • καταγράφηκε,
χωρίς tuning

8 άτομα

TEST • τελική αξιολόγηση

Κανένα άτομο δεν εμφανίζεται σε δύο σύνολα • seed = 42

Δύο MLlib μέθοδοι — τέσσερις συνθήκες

06

Multinomial Logistic Regression

απλό γραμμικό baseline • πιθανότητα ανά δραστηριότητα • maxIter=80 • L2=0.05

Random Forest

Συνδυάζει πιθανότητες από 80 δέντρα • depth=12 • sqrt

1 Phone accel

window 5 s

2 Phone accel + gyro

window 5 s

3 Phone accel + gyro

window 10 s


4 Watch accel + gyro

window 10 s

Μετρικές accuracy • macro-F1 • precision/recall • confusion matrix • χρόνοι

Πώς μαθαίνει η Logistic Regression;

Απλοποιημένο παράδειγμα: μία τιμή x • δύο δραστηριότητες



$$p(y=1|x) = 1 / (1 + e^{-(b_0 + b_1 x)})$$

Τι μαθαίνει;

- Τις τιμές των συντελεστών b_0 και b_1 .
- Οι συντελεστές μετακινούν και αλλάζουν την κλίση της καμπύλης.
- Στόχος: υψηλή πιθανότητα στη σωστή γνωστή δραστηριότητα.


Στο πραγματικό πείραμα

36 χαρακτηριστικά • 18 δραστηριότητες
Softmax: μετατρέπει τα 18 scores σε πιθανότητες που αθροίζουν σε 100%.

Πώς μαθαίνει το Random Forest;

08


Κάθε κόμβος επιλέγει χαρακτηριστικό και αριθμητικό όριο (threshold).



Ενδεικτικά όρια σε τυποποιημένα χαρακτηριστικά — όχι μετρήσεις του run.
Τα φύλλα δείχνουν εδώ μόνο την επικρατέστερη κλάση.


Τι μαθαίνει; ποιο feature και ποιο threshold χωρίζει καλύτερα τις δραστηριότητες.

80 διαφορετικά δέντρα



τυχαία δείγματα + διαφορετικά subsets χαρακτηριστικών

Παράδειγμα: 3 δέντρα, 2 δραστηριότητες



Μέσος όρος: W 60% • J 40%

Μεγαλύτερη πιθανότητα → WALKING

W = walking • J = jogging

Ίδιο PySpark pipeline: τοπικά και στο Google Cloud

09

LOCAL


ανάπτυξη και γρήγορες δοκιμές

- Debian + Python 3.11 + Java 17
- PySpark 3.5.3 • local[6]
- Parquet features • timestamped runs

GOOGLE CLOUD

διαχειριζόμενη κατανεμημένη εκτέλεση


- Private Cloud Storage bucket
- Managed Spark runtime 2.3 LTS
- Service account • no key file
- Serverless batch • europe-west1



Serverless: προσωρινοί Spark workers δημιουργούνται για το batch και τερματίζονται μετά.

Αποτελέσματα: το Random Forest κερδίζει παντού

10



62,14%

best test accuracy

61,90%

best macro-F1

**Watch fused 10 s
Random Forest**


Accuracy = ποσοστό σωστών προβλέψεων

F1 = ισορροπία precision και recall

Macro-F1 = μέσο F1 των 18 δραστηριοτήτων • τυχαία επιλογή $\approx 5,56\%$

Τι αλλάζει την επίδοση;

11



Ευρήματα

- Gyroscope: μικρή αλλά σταθερή βελτίωση στο phone.
- 10 s window: μικρό κέρδος έναντι 5 s.
- Watch: η μεγαλύτερη αλλαγή — πολλές κλάσεις είναι κινήσεις χεριού.
- Random Forest: +13,42 μονάδες macro-F1 στο κύριο πείραμα.

F1 score


Ισορροπεί precision (αξιοπιστία πρόβλεψης) και recall (πόσα πραγματικά παραδείγματα βρίσκονται).

Macro-F1: μέσο F1, με ίδιο βάρος και στις 18 δραστηριότητες.


Πού κάνει λάθη το καλύτερο μοντέλο;

12

Αριστερά: πραγματική δραστηριότητα × πρόβλεψη — η σκούρα διαγώνιος είναι σωστή πρόβλεψη.




Δεξιά: F1 ανά δραστηριότητα — μεγαλύτερη μπάρα σημαίνει καλύτερη ισορροπία precision/recall.



Παρόμοιες λεπτές κινήσεις συγχέονται — γι' αυτό αναφέρουμε macro-F1, όχι μόνο accuracy.

Χρόνος, cloud evidence και αναπαραγωγιμότητα

13



SUCCEEDED

cloud batch state

44m 47s

cloud elapsed

13.38 DCU-h

υπολογιστική χρήση — όχι τιμή σε ευρώ

Αναπαραγωγιμότητα

SHA-256 • YAML • deterministic split • tests • Parquet • saved models • JSON metrics

DCU-h = συνολική εργασία των managed Spark πόρων. Τα 44m 47s περιλαμβάνουν provisioning, preprocessing, training και αποθήκευση.

batch: har-watch-10s-20260827-055742

62,14%

RF • watch accel+gyro • 10 s

35 / 8 / 8

participant-disjoint split

Local + Cloud

ίδιο PySpark pipeline

ΟΡΙΑ

Το 62% είναι πολύ πάνω από την τυχαία επιλογή, αλλά δεν αρκεί για ιατρική ή safety-critical χρήση.

Παραδοτέα: κώδικας • tests • configs • metrics/models • cloud evidence • report • slides

Επόμενο βήμα: FFT / overlapping windows / CNN-LSTM baseline