

Κατανεμημένη Αναγνώριση Ανθρώπινης Δραστηριότητας με PySpark MLlib στο Google Cloud

Σύγκριση Πολυταξικής Λογιστικής Παλινδρόμησης και Random Forest στο WISDM

Κώστας Φύκατας
Ακαδημαϊκό έτος 2025–2026

Περίληψη

Η εργασία μελετά την αναγνώριση ανθρώπινων δραστηριοτήτων από μετρήσεις κινητού τηλεφώνου και έξυπνου ρολογιού. Χρησιμοποιείται το ανοικτό σύνολο δεδομένων WISDM, με 15.630.426 μετρήσεις από 51 συμμετέχοντες και 18 δραστηριότητες. Η εφαρμογή αναπτύχθηκε σε PySpark και καλύπτει όλη τη διαδικασία: ανάγνωση και έλεγχο των δεδομένων, δημιουργία χρονικών παραθύρων, υπολογισμό χαρακτηριστικών, συνένωση αισθητήρων, εκπαίδευση και αξιολόγηση. Συγκρίνονται δύο ταξινομητές της βιβλιοθήκης Spark MLlib: η πολυταξική Λογιστική Παλινδρόμηση και το Random Forest.

Η αξιολόγηση αφορά ανθρώπους που δεν συμμετείχαν στην εκπαίδευση. Για τον σκοπό αυτό, οι συμμετέχοντες χωρίστηκαν σε τρεις ομάδες: 35 για εκπαίδευση, 8 για επικύρωση και 8 για δοκιμή. Εξετάστηκαν τέσσερις συνδυασμοί συσκευής, αισθητήρων και διάρκειας παραθύρου. Την υψηλότερη τοπική επίδοση έδωσε το Random Forest με τους δύο αισθητήρες του ρολογιού και παράθυρα 10 s: 62,14% accuracy και 61,90% macro-F1, έναντι 49,96% και 48,48% της Λογιστικής Παλινδρόμησης. Η ίδια διαδικασία εκτελέστηκε και στο Google Cloud, με ιδιωτική αποθήκευση δεδομένων και υπολογιστικούς πόρους που διατίθενται για τη διάρκεια της εργασίας.

Λέξεις-κλειδιά: Apache Spark, PySpark, MLlib, cloud computing, WISDM, Human Activity Recognition, Random Forest, sensor fusion.

1. Εισαγωγή

Οι αισθητήρες ενός κινητού τηλεφώνου ή ενός έξυπνου ρολογιού καταγράφουν συνεχώς την κίνηση της συσκευής. Από αυτές τις μετρήσεις μπορούμε να προσπαθήσουμε να αναγνωρίσουμε τι κάνει ο χρήστης, για παράδειγμα αν περπατά, τρέχει ή γράφει. Το πρόβλημα αυτό ονομάζεται αναγνώριση ανθρώπινης δραστηριότητας, ή Human Activity Recognition (HAR).

Για να φτάσουμε από τις μετρήσεις σε μια πρόβλεψη, δεν αρκεί να επιλέξουμε έναν αλγόριθμο. Χρειάζεται να ελέγξουμε τα δεδομένα, να τα οργανώσουμε χρονικά, να συνδυάσουμε τους αισθητήρες και να επιλέξουμε τρόπο αξιολόγησης που να ανταποκρίνεται στον στόχο της εφαρμογής. Η εργασία εξετάζει αυτά τα βήματα με το Apache Spark και στη συνέχεια μεταφέρει την εφαρμογή στο νέφος.

Τα ερευνητικά ερωτήματα είναι:

1. Ποιο μοντέλο αναγνωρίζει καλύτερα τις δραστηριότητες νέων συμμετεχόντων;
2. Τι διαφορά κάνουν η συσκευή, ο συνδυασμός αισθητήρων και η διάρκεια του παραθύρου;
3. Μπορεί η ίδια λογική επεξεργασίας να χρησιμοποιηθεί τοπικά και στο Google Cloud;
4. Πόσο περισσότερο χρόνο εκπαίδευσης απαιτεί η καλύτερη επίδοση και τι γνωρίζουμε για την κατανάλωση πόρων;

Η υλοποίηση συνδέει έτσι την προεπεξεργασία δεδομένων, την κατανεμημένη μηχανική μάθηση και την εκτέλεση σε υποδομή νέφους.

2. Θεωρητικό υπόβαθρο

2.1 Big Data και δεδομένα αισθητήρων

Το WISDM παρουσιάζει τέσσερα χαρακτηριστικά που συναντώνται συχνά στα Big Data. Ο **όγκος** του φτάνει τα 15,63 εκατομμύρια μετρήσεις. Η **ταχύτητα παραγωγής** αντιστοιχεί σε δειγματοληψία 20 Hz σε τέσσερις ροές αισθητήρων. Η **ποικιλία** προέρχεται από τις δύο συσκευές, τους διαφορετικούς αισθητήρες και τις 18 δραστηριότητες. Τέλος, η **ποιότητα των δεδομένων** επηρεάζεται από τον θόρυβο, τα κενά στις μετρήσεις, την ασυγχρονία των αισθητήρων και τις διαφορές μεταξύ ανθρώπων.

Μία στιγμιαία μέτρηση συνήθως δεν αρκεί για να περιγράψει μια δραστηριότητα. Για αυτό οι μετρήσεις συγκεντρώνονται σε χρονικά παράθυρα και κάθε παράθυρο περιγράφεται με έναν σταθερό αριθμό χαρακτηριστικών. Ένα μικρό παράθυρο αποτυπώνει πιο σύντομες αλλαγές, ενώ ένα μεγαλύτερο προσφέρει περισσότερες μετρήσεις για τη στατιστική περιγραφή της κίνησης, με μικρότερη όμως χρονική ανάλυση.

2.2 Apache Spark και MLlib

Το Apache Spark επιτρέπει την επεξεργασία δεδομένων παράλληλα, σε μία ή περισσότερες μηχανές. Στην εργασία χρησιμοποιούνται DataFrames, δηλαδή πίνακες με ονομασμένες στήλες, για την ανάγνωση των μετρήσεων, το φιλτράρισμα, την ομαδοποίηση σε χρονικά παράθυρα και τη συνένωση των αισθητήρων. Πάνω σε αυτή τη δομή βασίζεται και το DataFrame API μηχανικής μάθησης του MLlib.

Ο κώδικας περιγράφει τις πράξεις που χρειάζονται και το Spark οργανώνει την εκτέλεσή τους. Οι περισσότεροι μετασχηματισμοί δεν εκτελούνται αμέσως, αλλά όταν ζητηθεί κάποιο αποτέλεσμα, όπως η καταμέτρηση των εγγραφών ή η αποθήκευσή τους. Αυτό ονομάζεται *lazy evaluation*. Ο Catalyst, ο μηχανισμός βελτιστοποίησης του Spark SQL, επεξεργάζεται το σχέδιο πριν εκτελεστεί, ώστε να περιορίζονται οι περιττές εργασίες.

Ο driver συντονίζει την εφαρμογή, ενώ οι executors εκτελούν επιμέρους εργασίες σε τμήματα των δεδομένων, τα partitions. Για να υπολογιστούν τα χαρακτηριστικά ενός χρονικού παραθύρου, χρειάζεται να συνδυαστούν οι μετρήσεις που ανήκουν σε αυτό. Η διαδικασία μπορεί να απαιτεί ανακατανομή δεδομένων μεταξύ partitions, γνωστή ως *shuffle*. Ενδιάμεσα αποτελέσματα που χρησιμοποιούνται επανειλημμένα διατηρούνται με το cache. Το Spark κρατά επίσης τη διαδρομή υπολογισμού τους, το *lineage*, ώστε να μπορεί να τα υπολογίσει ξανά αν χαθούν.

Για την εκπαίδευση χρησιμοποιείται ένα Pipeline που συνδέει τέσσερα στάδια: τη μετατροπή των ετικετών δραστηριότητας σε αριθμούς (StringIndexer), τη συγκέντρωση των χαρακτηριστικών σε ένα διάνυσμα (VectorAssembler), την τυποποίησή τους (StandardScaler) και τον ταξινομητή. Μετά την εκπαίδευση, τα προσαρμοσμένα στάδια αποθηκεύονται μαζί. Έτσι, κάθε νέο παράδειγμα περνά από την ίδια επεξεργασία πριν ταξινομηθεί.

2.3 Υπολογιστικό νέφος

Η τοπική εκτέλεση διευκολύνει την ανάπτυξη και τον έλεγχο της εφαρμογής. Για τη δοκιμή στο νέφος χρησιμοποιήθηκε το Google Cloud Managed Service for Apache Spark. Η υπηρεσία διαθέτει τους πόρους για μια εργασία Spark και τους αποδεσμεύει όταν αυτή ολοκληρωθεί, χωρίς να χρειάζεται μόνιμο cluster.

Επιλέχθηκε η οικογένεια runtime 2.3 LTS, με Spark 3.5.x, Python 3.11 και Java 17. Τα δεδομένα και τα μοντέλα αποθηκεύτηκαν σε ιδιωτικό χώρο Cloud Storage στην περιοχή europe-west1.

3. Σύνολο δεδομένων και έλεγχος ποιότητας

3.1 Περιγραφή WISDM

Το WISDM διατίθεται από το UCI Machine Learning Repository. Περιλαμβάνει μετρήσεις επιταχυνσιομέτρου και γυροσκοπίου από κινητό τηλέφωνο και έξυπνο ρολόι. Κάθε γραμμή καταγράφει έναν συμμετέχοντα, τη δραστηριότητα, τον χρόνο και τις τιμές των τριών αξόνων:

subject_id, activity_code, timestamp, x, y, z;

Οι δραστηριότητες περιλαμβάνουν περπάτημα, τρέξιμο, ανέβασμα ή κατέβασμα σκάλας, κάθισμα, ορθοστασία, πληκτρολόγηση, γράψιμο, φαγητό και άλλες κινήσεις. Αρκετές μοιάζουν μεταξύ τους, ιδιαίτερα όσες περιλαμβάνουν λεπτές κινήσεις των χεριών.

Ιδιότητα	Τιμή
Συμμετέχοντες	51
Δραστηριότητες	18
Συχνότητα	20 Hz
Συνολικές ακατέργαστες μετρήσεις	15.630.426
Συσκευές	τηλέφωνο, ρολόι
Αισθητήρες ανά συσκευή	accelerometer, gyroscope
Άδεια	CC BY 4.0

3.2 Ακεραιότητα και αναπαραγωγιμότητα

Το αρχικό αρχείο διατηρήθηκε αυτούσιο. Για να μπορεί να ελεγχθεί ότι χρησιμοποιείται το ίδιο αρχείο σε επόμενες εκτελέσεις, υπολογίστηκε το αποτύπωμά του με SHA-256:

6e0147f181d8f5275918db65eeb9dc842a0185d37cb6b2f30cbf74ee6e205469

Κατά την ανάγνωση, ο κώδικας αφαιρεί το τελικό ;, χωρίζει τα πεδία και μετατρέπει τις αριθμητικές τιμές στους κατάλληλους τύπους. Απορρίπτει γραμμές με ελλιπή απαραίτητα πεδία, αποτυχημένες μετατροπές, άγνωστη δραστηριότητα, αρνητικό χρόνο ή μη αναγνωρισμένη συσκευή και αισθητήρα. Η τιμή μηδέν στον χρόνο επιτρέπεται. Ο έλεγχος αυτός αφορά τη μορφή των δεδομένων· δεν περιλαμβάνει ξεχωριστό έλεγχο για αριθμητικές τιμές NaN ή άπειρο.

Η καταμέτρηση των αρχείων έδωσε 7.217.388 ακατέργαστες γραμμές για το ρολόι και 8.413.038 για το τηλέφωνο, πριν από τους ελέγχους ποιότητας. Οι δύο αισθητήρες συνδυάζονται μόνο όταν αφορούν τον ίδιο συμμετέχοντα, δραστηριότητα, συσκευή και χρονικό παράθυρο. Δεν συνενώνονται απευθείας τηλέφωνο και ρολόι, επειδή οι χρονικές τους ενδείξεις δεν είναι κατ’ ανάγκη συγχρονισμένες.

4. Κατανεμημένη προεπεξεργασία

4.1 Χρονικά παράθυρα

Μια στιγμιαία μέτρηση δεν δείχνει πώς εξελίσσεται η κίνηση. Για αυτό συγκεντρώνονται διαδοχικές μετρήσεις σε χρονικά διαστήματα, τα παράθυρα. Κάθε παράθυρο δίνει ένα παράδειγμα για το μοντέλο, αντί να χρησιμοποιείται κάθε μέτρηση χωριστά.

Στην εργασία εξετάστηκαν παράθυρα 5 και 10 s. Με 20 μετρήσεις το δευτερόλεπτο αναμένονται περίπου 100 μετρήσεις σε 5 s και 200 σε 10 s. Στο κύριο πείραμα χρησιμοποιήθηκαν παράθυρα 10 s και κρατήθηκαν όσα είχαν τουλάχιστον 150 μετρήσεις ανά αισθητήρα. Έτσι απορρίπτονται τα πολύ ελλιπή παράθυρα, χωρίς να απαιτείται απόλυτα σταθερός ρυθμός καταγραφής.

Για να αντιστοιχιστεί μια μέτρηση στο παράθυρό της, η χρονική ένδειξη διαιρείται με τη διάρκεια του παραθύρου και κρατείται το ακέραιο μέρος:

$$window_i d = \left\lfloor \frac{timestamp}{T_w} \right\rfloor$$

Το T_w και το timestamp εκφράζονται στην ίδια μονάδα χρόνου. Η ομαδοποίηση διατηρεί χωριστά τις μετρήσεις κάθε συμμετέχοντα, δραστηριότητας, συσκευής και αισθητήρα.

4.2 Εξαγωγή χαρακτηριστικών

Για να αναγνωρίσει μια δραστηριότητα, το μοντέλο χρειάζεται μια περιγραφή της κίνησης μέσα σε κάθε χρονικό παράθυρο. Η μέση τιμή δείχνει τη μέση στάθμη των μετρήσεων, ενώ η τυπική απόκλιση δείχνει πόσο μεταβάλλονται. Δύο παράθυρα μπορεί να έχουν παρόμοια μέση τιμή, αλλά στο ένα οι μετρήσεις να παραμένουν σχεδόν σταθερές και στο άλλο να αλλάζουν έντονα. Οι συσχετίσεις δείχνουν αν οι τιμές διαφορετικών αξόνων αυξάνονται ή μειώνονται μαζί.

Στην εργασία υπολογίζονται 18 τέτοια χαρακτηριστικά για κάθε αισθητήρα:

- η μέση τιμή, η τυπική απόκλιση, το ελάχιστο και το μέγιστο των αξόνων x, y, z — 12 χαρακτηριστικά,
- η μέση τιμή και η τυπική απόκλιση του μέτρου $m = \sqrt{x^2 + y^2 + z^2}$ — 2 χαρακτηριστικά,
- η μέση τιμή του $E = x^2 + y^2 + z^2$, που στον κώδικα ονομάζεται «ενέργεια» — 1 χαρακτηριστικό,
- οι συσχετίσεις Pearson $corr(x, y)$, $corr(x, z)$ και $corr(y, z)$ — 3 χαρακτηριστικά.

Το μέτρο συνδυάζει τις τιμές των τριών αξόνων σε έναν αριθμό. Η «ενέργεια» εδώ είναι στατιστικό μέγεθος, όχι φυσική ενέργεια σε joule. Όταν συνδυάζονται επιταχυνσιόμετρο και γυροσκόπιο, κάθε παράθυρο περιγράφεται από 36 αριθμούς: 18 από κάθε αισθητήρα. Αυτή η περιγραφή είναι η είσοδος του μοντέλου.

Το Spark υπολογίζει τα χαρακτηριστικά με ομαδοποιήσεις πάνω στα δεδομένα, χωρίς να συγκεντρώνει όλες τις αρχικές μετρήσεις στη μνήμη του driver.

4.3 Διαχωρισμός συμμετεχόντων

Στόχος είναι να αναγνωρίζονται δραστηριότητες ανθρώπων που δεν έχουν εμφανιστεί στην εκπαίδευση. Για αυτό ο διαχωρισμός γίνεται ανά συμμετέχοντα και όχι ανά παράθυρο. Διαφορετικά, το μοντέλο θα μπορούσε να αξιοποιεί προσωπικά μοτίβα του ίδιου ανθρώπου που είχε ήδη δει.

Ο ίδιος σταθερός διαχωρισμός χρησιμοποιείται σε όλα τα πειράματα. Οι 51 συμμετέχοντες χωρίζονται ως εξής:

Split	Άτομα	Ρόλος
Train	35	προσαρμογή παραμέτρων μοντέλου
Validation	8	καταγραφή μεγεθών· χωρίς επιλογή υπερπαραμέτρων
Test	8	αξιολόγηση σε συμμετέχοντες εκτός εκπαίδευσης

Οι ρυθμίσεις των μοντέλων παρέμειναν σταθερές σε όλα τα πειράματα. Το σύνολο επικύρωσης δεν χρησιμοποιήθηκε για επιλογή ρυθμίσεων. Η σύγκριση των τεσσάρων συνθηκών βασίστηκε στα αποτελέσματα του συνόλου δοκιμής. Ο τρόπος παραγωγής του σταθερού διαχωρισμού περιγράφεται στην ενότητα 12 του τεχνικού συνοδευτικού.

5. Μοντέλα και μετρικές

5.1 Πολυταξική Λογιστική Παλινδρόμηση

Η Λογιστική Παλινδρόμηση χρησιμοποιείται εδώ για να επιλέξει ανάμεσα σε 18 δραστηριότητες. Για κάθε δραστηριότητα συνδυάζει τα χαρακτηριστικά του παραθύρου και υπολογίζει ένα σκορ. Κάθε χαρακτηριστικό πολλαπλασιάζεται με έναν συντελεστή, το βάρος του, πριν προστεθεί στα υπόλοιπα. Κατά την εκπαίδευση, το μοντέλο προσαρμόζει αυτά τα βάρη χρησιμοποιώντας παραδείγματα με γνωστή δραστηριότητα.

Από τα 18 σκορ προκύπτουν οι εκτιμώμενες πιθανότητες των δραστηριοτήτων και επιλέγεται η μεγαλύτερη. Η μετατροπή αυτή γίνεται με τη συνάρτηση softmax. Επειδή τα σκορ βασίζονται σε αθροίσματα σταθμισμένων χαρακτηριστικών, η μέθοδος είναι σχετικά απλή, αλλά μπορεί να δυσκολεύεται σε σύνθετες σχέσεις μεταξύ των χαρακτηριστικών.

Πριν από την εκπαίδευση, τα χαρακτηριστικά μετατρέπονται σε κοινή κλίμακα με τον StandardScaler. Οι τιμές που χρειάζεται αυτή η μετατροπή υπολογίζονται μόνο από τα δεδομένα εκπαίδευσης και χρησιμοποιούνται αμετάβλητες στη δοκιμή. Στην εργασία επιτράπηκαν έως 80 επαναλήψεις εκπαίδευσης. Οι υπόλοιπες ρυθμίσεις βρίσκονται στο Παράρτημα Α, ενώ οι μαθηματικοί υπολογισμοί εξηγούνται στο τεχνικό συνοδευτικό.

5.2 Random Forest

Το Random Forest αναγνωρίζει μια δραστηριότητα συνδυάζοντας πολλά δέντρα αποφάσεων. Κάθε δέντρο λειτουργεί σαν μια σειρά ερωτήσεων για την κίνηση: «Είναι μεγάλη η μέση επιτάχυνση;», «Μεταβάλλονται έντονα οι τιμές του γυροσκοπίου;». Ανάλογα με την απάντηση, ακολουθεί διαφορετικό κλαδί μέχρι να καταλήξει σε μια εκτίμηση της δραστηριότητας. Οι ερωτήσεις και τα όριά τους μαθαίνονται από τα παραδείγματα εκπαίδευσης.

Τα δέντρα διαφέρουν μεταξύ τους, επειδή εκπαιδεύονται με τυχαίες διαφοροποιήσεις στα δεδομένα και στα χαρακτηριστικά που εξετάζουν. Έτσι δεν κάνουν πάντα τα ίδια λάθη. Συνδυάζοντας τις εκτιμήσεις τους, το Random Forest επιδιώκει πιο σταθερές προβλέψεις από ένα μεμονωμένο δέντρο.

Στην εργασία χρησιμοποιήθηκαν 80 δέντρα με μέγιστο βάθος 12. Το βάθος περιορίζει πόσα διαδοχικά βήματα απόφασης μπορεί να περιλαμβάνει μια διαδρομή μέσα στο δέντρο. Οι υπόλοιπες ρυθμίσεις παρουσιάζονται στο Παράρτημα Α. Το τεχνικό συνοδευτικό εξηγεί την εκπαίδευση των δέντρων και τον συνδυασμό των εκτιμήσεών τους στο Spark [8].

5.3 Μετρικές

Η αξιολόγηση εξετάζει πρώτα πόσες προβλέψεις είναι σωστές συνολικά. Αυτό το ποσοστό είναι η **accuracy**. Χρειάζεται όμως να εξεταστεί και κάθε δραστηριότητα χωριστά, ώστε μια καλή συνολική επίδοση να μην κρύβει δυσκολίες σε συγκεκριμένες κινήσεις.

Για παράδειγμα, για το περπάτημα τίθενται δύο διαφορετικά ερωτήματα. Από όσα παράθυρα το μοντέλο χαρακτήρισε ως περπάτημα, πόσα ήταν πράγματι περπάτημα; Αυτό μετρά το **precision**. Από όλα τα πραγματικά παράθυρα περπατήματος, πόσα εντόπισε; Αυτό μετρά το **recall**. Το **F1** συνδυάζει τις δύο μετρικές, ώστε να λαμβάνονται υπόψη τόσο οι λανθασμένες προβλέψεις όσο και οι περιπτώσεις που χάθηκαν.

Υπολογίζεται ένα F1 για καθεμία από τις 18 δραστηριότητες. Ο απλός μέσος τους είναι το **macro-F1**: κάθε δραστηριότητα έχει το ίδιο βάρος, ανεξάρτητα από το πλήθος των παραδειγμάτων της. Για αυτό χρησιμοποιείται μαζί με την accuracy στη βασική σύγκριση.

Στους τύπους, TP είναι οι σωστές προβλέψεις μιας δραστηριότητας, FP οι περιπτώσεις που προβλέφθηκαν λανθασμένα ως αυτή και FN τα πραγματικά παραδείγματά της που ταξινομήθηκαν αλλού:

$$P = \frac{TP}{TP + FP}, R = \frac{TP}{TP + FN}, F1 = \frac{2PR}{P + R}, macro-F1 = \frac{1}{18} \sum_{k=1}^{18} F1_k.$$


Στον κώδικα, όταν κάποιος λόγος δεν ορίζεται, λαμβάνει τιμή μηδέν. Καταγράφονται ακόμη οι μέσοι όροι precision και recall ανά δραστηριότητα, καθώς και το weighted-F1, όπου οι δραστηριότητες με περισσότερα παραδείγματα έχουν μεγαλύτερο βάρος. Ο πίνακας σύγχυσης δείχνει ποιες δραστηριότητες μπερδεύονται μεταξύ τους. Το τεχνικό συνοδευτικό περιλαμβάνει αριθμητικά παραδείγματα των υπολογισμών.

Η υπολογιστική επίδοση εξετάζεται χωριστά, με τους χρόνους εκπαίδευσης και πρόβλεψης και τις προβλέψεις ανά δευτερόλεπτο.

6. Αρχιτεκτονική υλοποίησης

6.1 Ροή δεδομένων

Η εφαρμογή χωρίζεται σε αρχεία με διακριτούς ρόλους. Το ingest.py διαβάζει και ελέγχει τις γραμμές. Το features.py δημιουργεί τα παράθυρα και τα χαρακτηριστικά, συνενώνει τους αισθητήρες και χωρίζει τους συμμετέχοντες. Το model.py περιέχει τα μοντέλα και τις μετρικές, ενώ το pipeline.py συντονίζει τα στάδια. Οι τοπικές εντολές δίνονται μέσω του cli.py και οι ρυθμίσεις αποθηκεύονται σε αρχεία YAML.



Σχήμα 1. Ροή επεξεργασίας: έλεγχος, χαρακτηριστικά, διαχωρισμός και δύο ταξινομητές. Πηγή: ingest.py, features.py, model.py και pipeline.py.

Τα χαρακτηριστικά μπορούν να αποθηκευτούν σε Parquet πριν από την εκπαίδευση και να χρησιμοποιηθούν ξανά σε επόμενα πειράματα. Το τελευταίο βήμα του σχήματος αφορά την αποθήκευση των εκπαιδευμένων μοντέλων και των αποτελεσμάτων.

6.2 Τοπικό περιβάλλον

Η τοπική εκτέλεση έγινε σε Debian, με Python 3.11, OpenJDK 17 και PySpark 3.5.3 σε απομονωμένο περιβάλλον Python. Η ρύθμιση local[6] επιτρέπει έως έξι νήματα στην ίδια μηχανή, ενώ για τον driver ορίστηκαν 4 GiB μνήμης.

Η αποθήκευση σε Parquet επιτρέπει την επανάληψη της εκπαίδευσης χωρίς νέα ανάγνωση και ανάλυση εκατομμυρίων αρχικών γραμμών. Παραμένει τοπική παράλληλη εκτέλεση: τα partitions δεν αντιστοιχούν εδώ σε διαφορετικές φυσικές μηχανές.

6.3 Google Cloud

Για την εκτέλεση στο νέφος δημιουργήθηκαν το project har-wisdm-student-2026 και το ιδιωτικό bucket har-wisdm-student-2026-data στην περιοχή europe-west1. Στα στοιχεία της εκτέλεσης της 27-08-2026 καταγράφονται ενεργά τα Uniform Bucket-Level Access και Public Access Prevention, για ενιαίο έλεγχο πρόσβασης στο bucket και αποτροπή δημόσιας πρόσβασης.

Η εφαρμογή εκτελέστηκε με service account, χωρίς αρχείο κλειδιού. Του δόθηκαν οι ρόλοι Dataproc worker, log writer και πρόσβασης στα αντικείμενα του συγκεκριμένου bucket. Ο χρήστης είχε το δικαίωμα iam.serviceAccountUser για την υποβολή της εργασίας με αυτόν τον λογαριασμό.

Η εργασία υποβάλλεται ως batch και δεν απαιτεί μόνιμο cluster. Ορίστηκε επίσης ειδοποίηση προϋπολογισμού €10, στα όρια 50%, 80% και 100%. Η ειδοποίηση ενημερώνει για την κατανάλωση, αλλά δεν διακόπτει αυτόματα τις χρεώσεις.

7. Πειραματικός σχεδιασμός

Εξετάστηκαν τέσσερις συνθήκες, με τα ίδια δύο μοντέλα και τον ίδιο διαχωρισμό συμμετεχόντων:

1. Επιταχυνσιόμετρο τηλεφώνου, με παράθυρα 5 s.
2. Επιταχυνσιόμετρο και γυροσκόπιο τηλεφώνου, με παράθυρα 5 s.
3. Επιταχυνσιόμετρο και γυροσκόπιο τηλεφώνου, με παράθυρα 10 s.
4. Επιταχυνσιόμετρο και γυροσκόπιο ρολογιού, με παράθυρα 10 s.

Τα σύνολα δοκιμής περιέχουν αντίστοιχα 5.178, 5.102, 2.534 και 2.488 παράθυρα. Μέσα σε κάθε συνθήκη, τα δύο μοντέλα χρησιμοποιούν ακριβώς τα ίδια δεδομένα.


Μεταξύ συνθηκών, όμως, το πλήθος αλλάζει, επειδή επηρεάζεται από τη διάρκεια του παραθύρου, τα φίλτρα και τη διαθεσιμότητα και των δύο αισθητήρων.

Μετά τη συνένωση των αισθητήρων προέκυψαν συνολικά 32.369 παράθυρα για το τηλέφωνο στα 5 s, 15.968 για το τηλέφωνο στα 10 s και 15.910 για το ρολόι στα 10 s. Οι τοπικοί χρόνοι εκπαίδευσης μετρήθηκαν από τα αποθηκευμένα χαρακτηριστικά Parquet, χωριστά από την αρχική προεπεξεργασία.

8. Αποτελέσματα


8.1 Ποιότητα πρόβλεψης

Τα διαγράμματα και ο πίνακας συνοψίζουν την επίδοση των δύο μοντέλων στις τέσσερις συνθήκες.



Σχήμα 2. Accuracy στο test για τις τέσσερις συνθήκες. Πηγή: τα τέσσερα αποθηκευμένα comparison.json της 27-08-2026.

Συνθήκη	Μοντέλο	Accuracy	Macro-F1	Train (s)	Inference (s)
Phone accel 5 s	Logistic Regression	19,68%	16,41%	10,39	0,29
Phone accel 5 s	Random Forest	28,66%	27,17%	28,07	1,84
Phone fused 5 s	Logistic Regression	22,11%	20,12%	15,72	0,38
Phone fused 5 s	Random Forest	30,95%	28,04%	28,24	1,68
Phone fused 10 s	Logistic Regression	22,73%	20,72%	11,33	0,30
Phone fused 10 s	Random Forest	31,45%	28,60%	20,09	1,29
Watch fused 10 s	Logistic Regression	49,96%	48,48%	10,58	0,32
Watch fused 10 s	Random Forest	62,14%	61,90%	22,17	1,51




Σχήμα 3. Macro-F1 ανά συνθήκη και μοντέλο. Πηγή: results/*/comparison.json, 27-08-2026.

Το Random Forest πέτυχε υψηλότερη accuracy και macro-F1 και στις τέσσερις συνθήκες. Στο κύριο πείραμα του ρολογιού, η διαφορά από τη Λογιστική Παλινδρόμηση είναι 12,18 ποσοστιαίες μονάδες στην accuracy και 13,42 στο macro-F1. Η accuracy 62,14% απέχει σημαντικά από το 5,56% μιας ομοιόμορφης τυχαίας επιλογής ανάμεσα σε 18 κλάσεις, αλλά αφήνει ακόμη σημαντικό περιθώριο βελτίωσης.

Στο τηλέφωνο, η προσθήκη γυροσκοπίου αύξησε την accuracy του Random Forest από 28,66% σε 30,95%. Με παράθυρο 10 s έφτασε το 31,45%. Η μεγαλύτερη διαφορά εμφανίστηκε με το ρολόι. Μια πιθανή εξήγηση είναι ότι πολλές δραστηριότητες, όπως η πληκτρολόγηση, το γράψιμο και το φαγητό, περιλαμβάνουν κινήσεις του καρπού. Η σύγκριση είναι συμβατή με αυτή την ερμηνεία, χωρίς να απομονώνει τη θέση της συσκευής ως μοναδική αιτία.


8.2 Ποιες δραστηριότητες συγχέονται

Ο πίνακας σύγχυσης επιτρέπει να εξεταστούν τα σφάλματα πέρα από έναν συνολικό αριθμό. Οι γραμμές δείχνουν την πραγματική δραστηριότητα και οι στήλες την πρόβλεψη.



Σχήμα 4. Random Forest, ρολόι/10 s: πραγματική δραστηριότητα στις γραμμές και πρόβλεψη στις στήλες. Κάθε γραμμή κανονικοποιείται στο 100%. Πηγή: 20260827T054435Z/random_forest/confusion.json.


Στο κύριο σύνολο δοκιμής, 51 από τα 141 παράθυρα πληκτρολόγησης προβλέφθηκαν ως γράψιμο. Το F1 κυμαίνεται από περίπου 26,0% για την κατανάλωση σάντουιτς έως 91,0% για το τρέξιμο. Οι έντονες, επαναλαμβανόμενες κινήσεις διακρίνονται ευκολότερα από αρκετές λεπτές κινήσεις των χεριών. Για αυτό η accuracy από μόνη της δεν αρκεί: το F1 ανά δραστηριότητα και το macro-F1 δείχνουν καλύτερα πού αποδίδει και πού δυσκολεύεται το μοντέλο.



Σχήμα 5. F1 ανά δραστηριότητα, Random Forest ρολόι/10 s. Πηγή: 20260827T054435Z/random_forest/metrics.json.

8.3 Χρόνος εκπαίδευσης

Το Random Forest χρειάστηκε περισσότερο χρόνο εκπαίδευσης και πρόβλεψης και στις τέσσερις συνθήκες.



Σχήμα 6. Τοπικός χρόνος pipeline.fit σε δευτερόλεπτα. Πηγή: τα τέσσερα comparison.json της 27-08-2026.

Στο κύριο τοπικό πείραμα, η εκπαίδευσή του διήρκεσε 22,17 s, έναντι 10,58 s της Λογιστικής Παλινδρόμησης. Χρειάστηκε δηλαδή περίπου 2,1 φορές περισσότερο χρόνο, ή 11,59 επιπλέον δευτερόλεπτα, για βελτίωση της accuracy κατά 12,18 ποσοστιαίες μονάδες. Για το συγκεκριμένο μέγεθος δεδομένων, η επιπλέον αναμονή είναι μικρή σε απόλυτους χρόνους. Η πρόβλεψη παραμένει σύντομη και στις δύο μεθόδους, παρότι το Random Forest είναι περίπου 4,7 φορές βραδύτερο.

Ο χρόνος εκπαίδευσης καλύπτει όλο το pipeline.fit(train), μαζί με την προσαρμογή του indexer και του scaler. Ο χρόνος πρόβλεψης περιλαμβάνει transform, cache και count, ώστε οι προβλέψεις να υπολογιστούν και όχι απλώς να περιγραφούν ως σχέδιο εκτέλεσης. Οι τιμές προέρχονται από μεμονωμένες εκτελέσεις και δεν αποτελούν μέτρηση χρηματικού κόστους.

8.4 Εκτέλεση στο νέφος

Στο Google Cloud χρησιμοποιήθηκαν οι ίδιοι κανόνες ανάγνωσης, παραθύρων, χαρακτηριστικών και διαχωρισμού συμμετεχόντων, καθώς και οι ίδιες υπερπαράμετροι. Το batch har-watch-10s-20260827-055742 ολοκληρώθηκε επιτυχώς (**SUCCEEDED**) με runtime 2.3.39 σε 44 min 47 s.

Η υπηρεσία κατέγραψε 48.174.200 milli-DCU-seconds, δηλαδή 13,38 DCU-hours υπολογιστικής χρήσης. Κατέγραψε επίσης 4.878.400 shuffle-storage GB-seconds, δηλαδή 1.355,11 GB-hours, για αποθήκευση δεδομένων shuffle. Το δεύτερο μέγεθος συνδυάζει χώρο και χρόνο αποθήκευσης· δεν είναι όγκος δικτυακής μεταφοράς. Παρήχθησαν 122 αντικείμενα συνολικού μεγέθους 8,4 MB, με τα δύο μοντέλα και τα αποτελέσματά τους.

Cloud μοντέλο	Accuracy	Macro-F1	Training	Inference
Logistic Regression	49,96%	48,48%	265,23 s	12,09 s
Random Forest	61,54%	61,09%	1.911,81 s	77,81 s

Η Λογιστική Παλινδρόμηση έδωσε τις ίδιες μετρικές με την τοπική εκτέλεση. Το Random Forest είχε χαμηλότερη accuracy κατά 0,60 ποσοστιαίες μονάδες και macro-F1 κατά 0,81. Παρότι δεδομένα, διαχωρισμός και ρυθμίσεις συμφωνούν, η κατασκευή των δέντρων μπορεί να επηρεάζεται από τη σειρά των δεδομένων, τα partitions και λεπτομέρειες του περιβάλλοντος. Δεν έγιναν επαναληπτικές δοκιμές για να εντοπιστεί η συγκεκριμένη αιτία. Και στα δύο περιβάλλοντα, πάντως, το Random Forest είχε την υψηλότερη επίδοση.

Ο συνολικός χρόνος του cloud περιλαμβάνει τη διάθεση πόρων, την ανάγνωση 405,96 MB αρχικών δεδομένων, την προεπεξεργασία, την εκπαίδευση και την αποθήκευση. Οι τοπικοί χρόνοι ξεκινούν από έτοιμα χαρακτηριστικά Parquet. Συνεπώς, οι μετρήσεις τεκμηριώνουν ότι η εφαρμογή εκτελέστηκε στο νέφος, αλλά δεν προσφέρουν άμεση σύγκριση ταχύτητας των δύο υποδομών.

9. Συζήτηση

9.1 Απαντήσεις στα ερευνητικά ερωτήματα

1. **Ποιο μοντέλο απέδωσε καλύτερα;** Το Random Forest αναγνώρισε καλύτερα τις δραστηριότητες των νέων συμμετεχόντων σε όλες τις εξεταζόμενες συνθήκες.
2. **Τι άλλαξε με τους αισθητήρες και τα παράθυρα;** Η συνένωση αισθητήρων και τα μεγαλύτερα παράθυρα βελτίωσαν την επίδοση στο τηλέφωνο. Η μεγαλύτερη βελτίωση καταγράφηκε με τα δεδομένα του ρολογιού.
3. **Μεταφέρθηκε η εφαρμογή στο νέφος;** Η ίδια λογική επεξεργασίας εκτελέστηκε τοπικά και στο Google Cloud, με διαφορετικά προγράμματα εκκίνησης.
4. **Ποιο ήταν το τίμημα σε χρόνο;** Στο κύριο τοπικό πείραμα, το Random Forest χρειάστηκε 22,17 s για εκπαίδευση, έναντι 10,58 s της Λογιστικής Παλινδρόμησης: περίπου 2,1 φορές περισσότερο χρόνο, ή 11,59 s επιπλέον. Η κατανάλωση πόρων καταγράφηκε για την εργασία στο νέφος, αλλά δεν μετρήθηκε οικονομία ή επιτάχυνση με περισσότερες μηχανές.

9.2 Αρχιτεκτονικές εναλλακτικές

Μια εναλλακτική είναι να δοθούν οι χρονικές ακολουθίες απευθείας σε ένα νευρωνικό δίκτυο, όπως CNN ή LSTM. Το μοντέλο θα μπορούσε τότε να μάθει μοτίβα που χάνονται όταν κρατάμε μόνο στατιστικές συνόψεις. Θα χρειαζόταν όμως διαφορετική προετοιμασία ακολουθιών, εκπαίδευση σε παρτίδες και περισσότερες ρυθμίσεις. Η χρήση GPU θα μπορούσε να διευκολύνει την εκπαίδευση, χωρίς να είναι υποχρεωτική σε κάθε περίπτωση. Τυχόν βελτίωση θα έπρεπε να επιβεβαιωθεί πειραματικά.

Για τις 15.910 τελικές εγγραφές του κύριου πειράματος, η scikit-learn θα πρόσφερε απλούστερη τοπική υλοποίηση. Δεν μετρήθηκε η ταχύτητά της. Η επιλογή Spark επιτρέπει να μελετηθεί στην ίδια εφαρμογή τόσο η κατανεμημένη προεπεξεργασία των αρχικών μετρήσεων όσο και η εκπαίδευση στο νέφος.

9.3 Περιορισμοί

- Τα δεδομένα συλλέχθηκαν σε ελεγχόμενες συνθήκες. Το δείγμα των 51 συμμετεχόντων περιορίζει τη γενίκευση στην καθημερινή χρήση και σε ευρύτερο πληθυσμό.
- Οι στατιστικές συνόψεις δεν διατηρούν ολόκληρη τη χρονική σειρά των μετρήσεων. Η συνένωση αισθητήρων απορρίπτει παράθυρα όταν λείπει το έγκυρο αντίστοιχο του άλλου αισθητήρα.
- Η ομαδοποίηση χρησιμοποιεί την ήδη γνωστή δραστηριότητα. Δεν αξιολογήθηκε αυτόματη ανίχνευση μεταβάσεων σε συνεχή ροή, ενώ οι ετικέτες του συνόλου δεδομένων θεωρούνται σωστές.
- Χρησιμοποιήθηκε ένας σταθερός διαχωρισμός συμμετεχόντων, χωρίς αναζήτηση υπερπαραμέτρων, επαναλαμβανόμενη διασταυρούμενη επικύρωση ή διαστήματα εμπιστοσύνης.

- Η συνθήκη με την υψηλότερη επίδοση προέκυψε από τη σύγκριση στο σύνολο δοκιμής. Για να επιβεβαιωθεί η επιλογή της ανεξάρτητα από αυτή τη σύγκριση, θα χρειαζόταν νέο σύνολο δοκιμής.
- Οι χρόνοι προέρχονται από μεμονωμένες εκτελέσεις. Δεν έγινε σύγκριση επιτάχυνσης με περισσότερες μηχανές ούτε δοκιμή ανάκαμψης μετά από αστοχία.
- Δεν αξιολογήθηκαν η ισότιμη επίδοση σε διαφορετικές ομάδες χρηστών, η ενεργειακή κατανάλωση σε φορητή συσκευή ή η καταλληλότητα για κλινικές εφαρμογές.

9.4 Ασφάλεια και κόστος

Στην καταγεγραμμένη εγκατάσταση δεν δημιουργήθηκαν αρχεία κλειδιών service account, το bucket παρέμεινε ιδιωτικό και δεν ενσωματώθηκαν διαπιστευτήρια στον κώδικα. Η ανοικτή άδεια του WISDM επιτρέπει τη χρήση του, ενώ ο περιορισμός δικαιωμάτων προστατεύει και τα υπόλοιπα αρχεία της εφαρμογής.

Οι υπολογιστικοί πόροι του serverless batch αποδεσμεύονται μετά την ολοκλήρωσή του. Τα αποθηκευμένα δεδομένα μπορούν να συνεχίσουν να χρεώνονται. Τα στοιχεία της συγκεκριμένης εκτέλεσης δεν τεκμηριώνουν την τελική χρέωση ή τη σημερινή κατάσταση αυτών των πόρων.

10. Συμπεράσματα και μελλοντική εργασία

Η εργασία υλοποίησε μια ολοκληρωμένη διαδικασία αναγνώρισης δραστηριοτήτων: από την ανάγνωση και τον έλεγχο των μετρήσεων του WISDM έως την αξιολόγηση δύο μοντέλων σε νέους συμμετέχοντες και την εκτέλεση στο Google Cloud.

Το υψηλότερο τοπικό αποτέλεσμα προέκυψε με Random Forest, συνδυασμό των δύο αισθητήρων του ρολογιού και παράθυρα 10 s: 62,14% accuracy και 61,90% macro-F1. Η βελτίωση σε σχέση με τη Λογιστική Παλινδρόμηση συνοδεύτηκε από περισσότερο χρόνο εκπαίδευσης. Η ανάλυση ανά δραστηριότητα έδειξε επίσης ότι οι λεπτές κινήσεις των χεριών παραμένουν πιο δύσκολο να διακριθούν.

Οι επόμενες δοκιμές μπορούν να οργανωθούν γύρω από τρεις στόχους:

- **Πλουσιότερη περιγραφή της κίνησης.** Χαρακτηριστικά συχνότητας, υπολογισμένα με FFT, θα μπορούσαν να περιγράψουν επαναλαμβανόμενα μοτίβα. Επικαλυπτόμενα παράθυρα θα έδιναν περισσότερα παραδείγματα γύρω από χρονικές μεταβολές. Νευρωνικά δίκτυα, όπως CNN ή LSTM, θα επέτρεπαν να εξεταστεί η ίδια η ακολουθία των μετρήσεων, αντί μόνο των στατιστικών της.
- **Πιο αξιόπιστη σύγκριση μοντέλων.** Η επανάληψη της αξιολόγησης με διαφορετικές ομάδες συμμετεχόντων θα έδειχνε πόσο εξαρτάται το αποτέλεσμα από τον συγκεκριμένο διαχωρισμό. Θα μπορούσαν επίσης να δοκιμαστούν μεγαλύτερα βάρη για ορισμένες δραστηριότητες και άλλοι ταξινομητές, όπως ενισχυμένα δέντρα, με επιλογή ρυθμίσεων σε δεδομένα επικύρωσης.
- **Δοκιμή σε καθημερινή χρήση.** Η συνεχής εισαγωγή μετρήσεων θα απαιτούσε αναγνώριση χωρίς ήδη γνωστά όρια δραστηριοτήτων. Θα χρειαζόταν επίσης έλεγχος για το αν αλλάζουν με τον χρόνο οι κινήσεις ή οι συνθήκες καταγραφής.

Οι προτάσεις αυτές χρειάζονται νέα πειράματα· δεν αποτελούν βελτιώσεις που μετρήθηκαν στην παρούσα εργασία. Ο κώδικας, οι ρυθμίσεις και τα αποθηκευμένα αποτελέσματα επιτρέπουν την επανάληψη της διαδικασίας, χωρίς να εγγυώνται αριθμητικά ταυτόσημο αποτέλεσμα σε κάθε περιβάλλον.

Βιβλιογραφία

1. G. M. Weiss, “WISDM Smartphone and Smartwatch Activity and Biometrics Dataset,” UCI Machine Learning Repository, 2019. DOI: [10.24432/C5HK59](https://doi.org/10.24432/C5HK59).
2. UCI Machine Learning Repository, [WISDM dataset record](#), πρόσβαση 27-08-2026.
3. Apache Spark, [Machine Learning Library \(MLlib\) Guide](#), πρόσβαση 27-08-2026.
4. Apache Spark, [PySpark MLlib DataFrame API](#), πρόσβαση 27-08-2026.
5. Google Cloud, [Managed Service for Apache Spark serverless runtime versions](#), πρόσβαση 27-08-2026.
6. Google Cloud, [Serverless for Apache Spark overview](#), πρόσβαση 27-08-2026.

7. Σημειώσεις μαθήματος «Πλατφόρμες και Αρχιτεκτονικές Νέφους»: Big Data, προεπεξεργασία, Spark, βάσεις δεδομένων και cloud service models, 2025–2026.
8. Apache Spark 3.5.3, [RandomForestClassificationModel.predictRaw](#).

Παράρτημα Α — Ρυθμίσεις πειράματος και υπερπαράμετροι

Παράμετρος	Τιμή
seed	42
κύριο παράθυρο	10 s
ελάχιστα δείγματα	150
train/validation/test subjects	35/8/8
Logistic Regression maxIter	80
Logistic Regression regParam	0,05
Random Forest numTrees	80
Random Forest maxDepth	12
Random Forest feature subset	sqrt
Cloud region	europe-west1
Cloud runtime	2.3 LTS

Η Λογιστική Παλινδρόμηση χρησιμοποιεί family=multinomial και κανονικοποίηση L2 (elasticNetParam=0.0). Η L2 περιορίζει τα πολύ μεγάλα βάρη, με ισχύ που ορίζεται από το regParam. Στο Random Forest χρησιμοποιείται το κριτήριο Gini για την επιλογή διαχωρισμών. Η τιμή sqrt περιορίζει τα χαρακτηριστικά που εξετάζονται σε κάθε κόμβο στην τετραγωνική ρίζα του συνολικού πλήθους τους. Το seed 42 καθορίζει τις τυχαίες επιλογές της εκτέλεσης.